[Team 12 DS 3] - Final Presentation

[Data Science]

Anggota Tim

Kelas	TIM	NAMA
DS-3	**12**	- Muhamad Shidqi
		- Mohammad Rifqi Nur Faroza

Chapter 1. Covid-19 New Cases in Indonesia

BINAR

Studi kasusss??

Terdapat data yang sangat banyak tentang kasus covid-19 yang terjadi di Indonesia. Sebagai junior data scientist tim teknologi kesehatan, disini kita akan memberikan beberapa informasi dan insight terkait data covid-19 di Indonesia.

Sub Topic

Ada apa sih?

Ada apa aja sih di dalam data covid-19 di Indonesia??

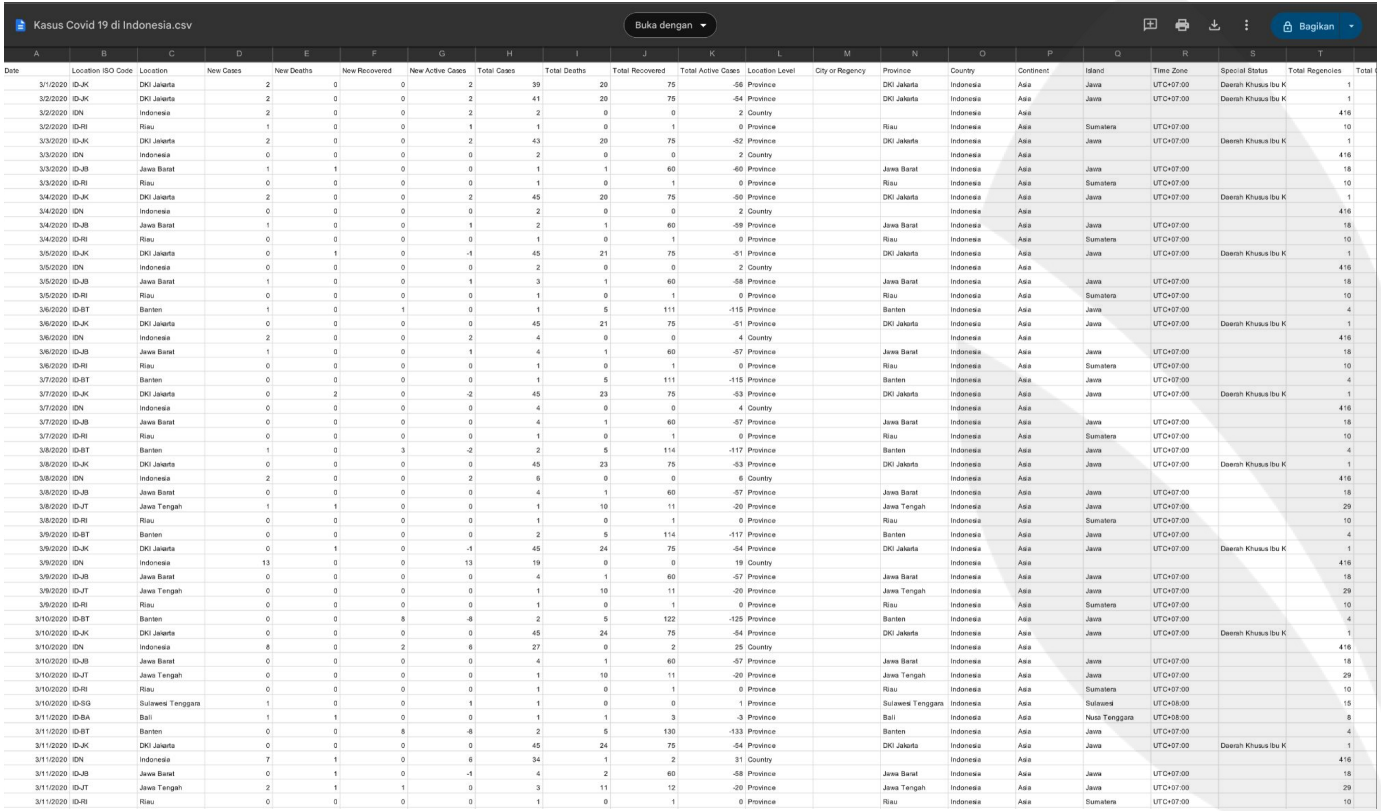
Kasus Covid 19 di Indonesia.csv

Buka dengan

Bagikan

Date	Location ISO Code	Location	New Cases	New Deaths	New Recovered	New Active Cases	Total Cases	Total Deaths	Total Recovered	Total Active Cases	Location Level	City or Regency	Province	Country	Continent	Island	Time Zone	Special Status	Total Regencies	Total
3/1/2020	ID-JK	DKI Jakarta	2	0	0	2	39	20	75	-56	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/2/2020	ID-JK	DKI Jakarta	2	0	0	2	41	20	75	-54	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/2/2020	IDN	Indonesia	2	0	0	2	2	0	0	2	Country			Indonesia	Asia				416	
3/2/2020	ID-RI	Riau	1	0	0	1	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/3/2020	ID-JK	DKI Jakarta	2	0	0	2	43	20	75	-52	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/3/2020	IDN	Indonesia	0	0	0	0	2	0	0	2	Country			Indonesia	Asia				416	
3/3/2020	ID-JB	Jawa Barat	1	1	0	0	1	1	60	-60	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/3/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/4/2020	ID-JK	DKI Jakarta	2	0	0	2	45	20	75	-50	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/4/2020	IDN	Indonesia	0	0	0	0	2	0	0	2	Country			Indonesia	Asia				416	
3/4/2020	ID-JB	Jawa Barat	1	0	0	1	2	1	60	-59	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/4/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/5/2020	ID-JK	DKI Jakarta	0	1	0	-1	45	21	75	-51	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/5/2020	IDN	Indonesia	0	0	0	0	2	0	0	2	Country			Indonesia	Asia				416	
3/5/2020	ID-JB	Jawa Barat	1	0	0	1	3	1	60	-58	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/5/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/6/2020	ID-BT	Banten	1	0	1	0	1	5	111	-115	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/6/2020	ID-JK	DKI Jakarta	0	0	0	0	45	21	75	-51	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/6/2020	IDN	Indonesia	2	0	0	2	4	0	0	4	Country			Indonesia	Asia				416	
3/6/2020	ID-JB	Jawa Barat	1	0	0	1	4	1	60	-57	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/6/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/7/2020	ID-BT	Banten	0	0	0	0	1	5	111	-115	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/7/2020	ID-JK	DKI Jakarta	0	2	0	-2	45	23	75	-53	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/7/2020	IDN	Indonesia	0	0	0	0	4	0	0	4	Country			Indonesia	Asia				416	
3/7/2020	ID-JB	Jawa Barat	0	0	0	0	4	1	60	-57	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/7/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/8/2020	ID-BT	Banten	1	0	3	-2	2	5	114	-117	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/8/2020	ID-JK	DKI Jakarta	0	0	0	0	45	23	75	-53	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/8/2020	IDN	Indonesia	2	0	0	2	6	0	0	6	Country			Indonesia	Asia				416	
3/8/2020	ID-JB	Jawa Barat	0	0	0	0	4	1	60	-57	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/8/2020	ID-JT	Jawa Tengah	1	1	0	0	1	10	11	-20	Province		Jawa Tengah	Indonesia	Asia	Jawa	UTC+07:00		29	
3/8/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/9/2020	ID-BT	Banten	0	0	0	0	2	5	114	-117	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/9/2020	ID-JK	DKI Jakarta	0	1	0	-1	45	24	75	-54	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/9/2020	IDN	Indonesia	13	0	0	13	19	0	0	19	Country			Indonesia	Asia				416	
3/9/2020	ID-JB	Jawa Barat	0	0	0	0	4	1	60	-57	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/9/2020	ID-JT	Jawa Tengah	0	0	0	0	1	10	11	-20	Province		Jawa Tengah	Indonesia	Asia	Jawa	UTC+07:00		29	
3/9/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/10/2020	ID-BT	Banten	0	0	8	-8	2	5	122	-125	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/10/2020	ID-JK	DKI Jakarta	0	0	0	0	45	24	75	-54	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/10/2020	IDN	Indonesia	8	0	2	6	27	0	2	25	Country			Indonesia	Asia				416	
3/10/2020	ID-JB	Jawa Barat	0	0	0	0	4	1	60	-57	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/10/2020	ID-JT	Jawa Tengah	0	0	0	0	1	10	11	-20	Province		Jawa Tengah	Indonesia	Asia	Jawa	UTC+07:00		29	
3/10/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	
3/10/2020	ID-SG	Sulawesi Tenggara	1	0	0	1	1	0	0	1	Province		Sulawesi Tenggara	Indonesia	Asia	Sulawesi	UTC+08:00		15	
3/11/2020	ID-BA	Bali	1	1	0	0	1	1	3	-3	Province		Bali	Indonesia	Asia	Nusa Tenggara	UTC+08:00		8	
3/11/2020	ID-BT	Banten	0	0	8	-8	2	5	130	-133	Province		Banten	Indonesia	Asia	Jawa	UTC+07:00		4	
3/11/2020	ID-JK	DKI Jakarta	0	0	0	0	45	24	75	-54	Province		DKI Jakarta	Indonesia	Asia	Jawa	UTC+07:00	Daerah Khusus Ibu K	1	
3/11/2020	IDN	Indonesia	7	1	0	6	34	1	2	31	Country			Indonesia	Asia				416	
3/11/2020	ID-JB	Jawa Barat	0	1	0	-1	4	2	60	-58	Province		Jawa Barat	Indonesia	Asia	Jawa	UTC+07:00		18	
3/11/2020	ID-JT	Jawa Tengah	2	1	1	0	3	11	12	-20	Province		Jawa Tengah	Indonesia	Asia	Jawa	UTC+07:00		29	
3/11/2020	ID-RI	Riau	0	0	0	0	1	0	1	0	Province		Riau	Indonesia	Asia	Sumatera	UTC+07:00		10	

Sub Topic

Step 1

Pertama tentunya kita akan import data ke Big Query

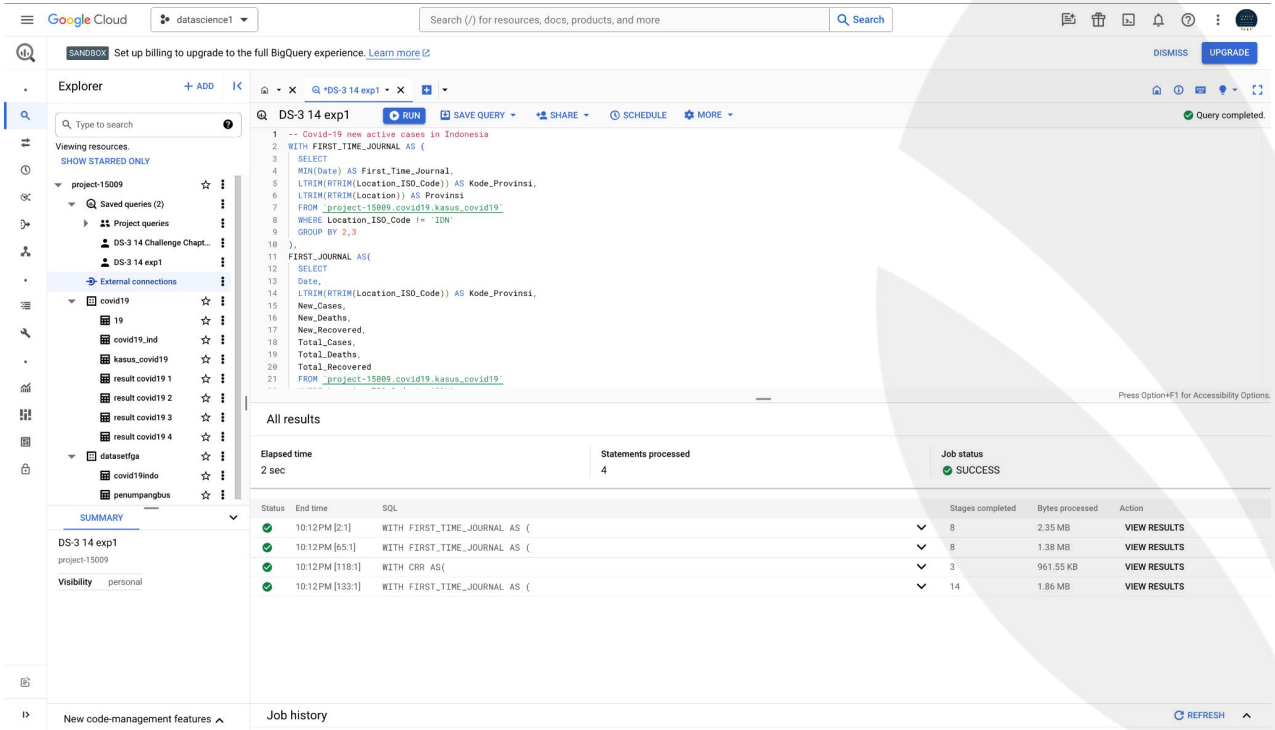

BINAR

Step 2

Setelah data dataset di import ke BigQuery kita dapat melakukan beberapa query

```sql
-- Covid-19 new active cases in Indonesia
WITH FIRST_TIME_JOURNAL AS (
  SELECT
  MIN(Date) AS First_Time_Journal,
  LTRIM(RTRIM(Location_ISO_Code)) AS Kode_Provinsi,
  LTRIM(RTRIM(Location)) AS Provinsi
  FROM `project-15009.covid19.kasus_covid19`
  WHERE Location_ISO_Code != 'IDN'
  GROUP BY 2,3
),
FIRST_JOURNAL AS(
  SELECT
  Date,
  LTRIM(RTRIM(Location_ISO_Code)) AS Kode_Provinsi,
  New_Cases,
  New_Deaths,
  New_Recovered,
  Total_Cases,
  Total_Deaths,
  Total_Recovered
  FROM `project-15009.covid19.kasus_covid19`
  WHERE Location_ISO_Code != 'IDN'
),
OLD_CASES AS(
  SELECT
  a.Kode_Provinsi AS Kode_Provinsi,
  a.Provinsi,
  (b.Total_Cases - b.New_Cases) AS Kasus_Aktif_Awal,
  (b.Total_Deaths - b.New_Deaths) AS Kematian_Awal,
  (b.Total_Recovered - b.New_Recovered) AS Sembuh_Awal,
  FROM FIRST_TIME_JOURNAL AS a
  LEFT JOIN FIRST_JOURNAL AS b
  ON a.First_Time_Journal = b.Date AND a.Kode_Provinsi = b.Kode_Provinsi
),
NEW_CASES AS(
    SELECT
    LTRIM(RTRIM(Location_ISO_Code)) AS Kode_Provinsi,
    LTRIM(RTRIM(Location)) AS Provinsi,
    SUM(New_Cases) AS Kasus_Baru,
    SUM(New_Deaths) AS Kematian_Baru,
    SUM(New_Recovered) AS Sembuh_Baru,
    FROM `project-15009.covid19.kasus_covid19`
    WHERE Location_ISO_Code != 'IDN'
```

BINAR

Hasil query

Rank	Kode_Provinsi	Provinsi	Jumlah_Kasus_Aktif
1	ID-JB	Jawa Barat	13496
2	ID-JK	DKI Jakarta	10959
3	ID-BT	Banten	2558
4	ID-JT	Jawa Tengah	1423
5	ID-JI	Jawa Timur	1147
6	ID-YO	Daerah Istimewa Yogyakarta	669
7	ID-SU	Sumatera Utara	664
8	ID-SA	Sulawesi Utara	565
9	ID-BA	Bali	474
10	ID-SS	Sumatera Selatan	313
11	ID-KI	Kalimantan Timur	272
12	ID-PA	Papua	237
13	ID-LA	Lampung	226
14	ID-RI	Riau	224
15	ID-KT	Kalimantan Tengah	220
16	ID-SB	Sumatera Barat	204
17	ID-KS	Kalimantan Selatan	153
18	ID-SN	Sulawesi Selatan	153
19	ID-PB	Papua Barat	137
20	ID-KR	Kepulauan Riau	130

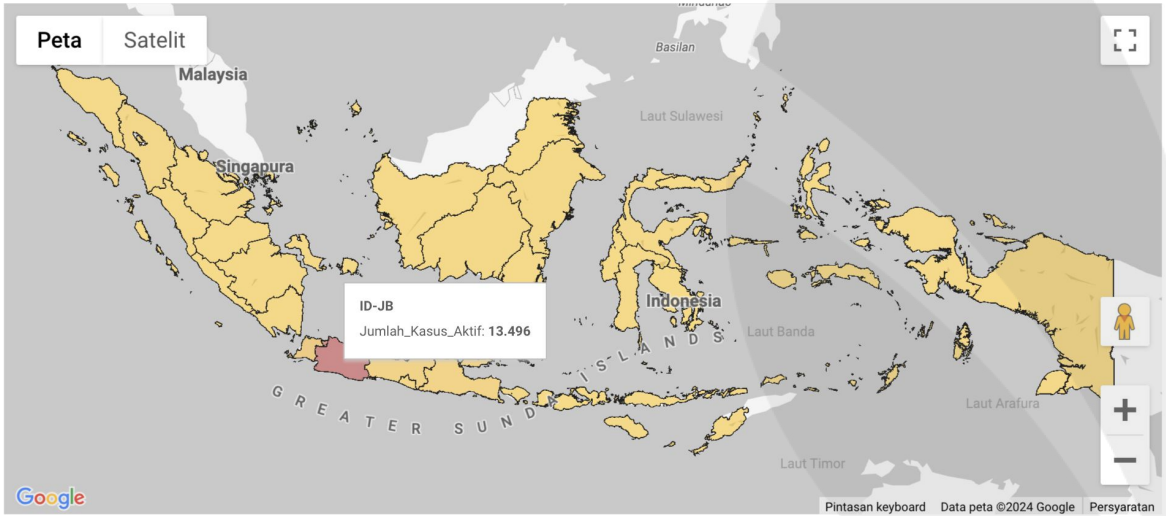

Sub Topic

Hasil query

Rank	Kode_Provinsi	Provinsi	Case Fatality Rate	Case Recovery Rate
1	ID-BT	Banten	0,89%	99,11%
2	ID-JK	DKI Jakarta	1,11%	98,89%
3	ID-PA	Papua	1,17%	98,83%
4	ID-PB	Papua Barat	1,20%	98,80%
5	ID-JB	Jawa Barat	1,37%	98,63%
6	ID-MA	Maluku	1,58%	98,42%
7	ID-NT	Nusa Tenggara Timur	1,62%	98,38%
8	ID-SN	Sulawesi Selatan	1,72%	98,28%
9	ID-KB	Kalimantan Barat	1,73%	98,27%
10	ID-BE	Bengkulu	1,79%	98,21%
11	ID-KU	Kalimantan Utara	1,89%	98,11%
12	ID-SU	Sumatera Utara	2,08%	97,92%
13	ID-SG	Sulawesi Tenggara	2,22%	97,78%
14	ID-SB	Sumatera Barat	2,27%	97,73%
15	ID-MU	Maluku Utara	2,29%	97,71%
16	ID-JA	Jambi	2,30%	97,70%
17	ID-SA	Sulawesi Utara	2,32%	97,68%
18	ID-BB	Kepulauan Bangka Belitung	2,45%	97,55%
19	ID-NB	Nusa Tenggara Barat	2,49%	97,51%
20	ID-SR	Sulawesi Barat	2,53%	97,47%

CRR
97

CFR
3

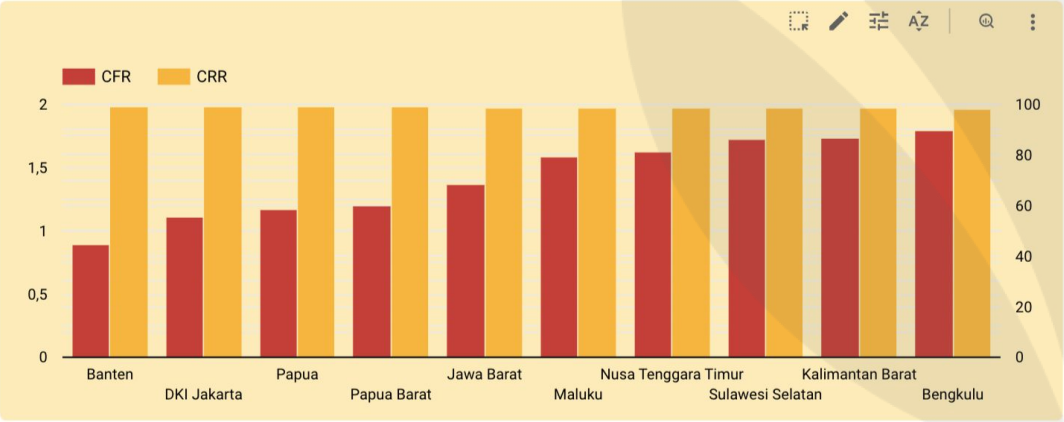

Kesimpulan

Dalam data tersebut terlihat bahwa, penyebaran kasus covid-19 di Indonesia paling banyak terletak di provinsi pada pulau jawa karena sering dijadikan destinasi wisata dan bisnis secara lokal dan internasional. Karena alasan tersebut persebaran covid-19 semakin cepat. Dan untuk tingkat kesembuhan penanganan pasien paling banyak di daerah provinsi besar yang ada di pulau jawa, mungkin dikarenakan akan kesadaran kesehatan dan fasilitas medis yang lebih baik diantara provinsi-provinsi yang lain.

Chapter 2. Churn Customer

Business problem??

Dalam beberapa bulan terakhir perusahaan StarTelco mengalami penurunan pendapatan yang diakibatkan banyaknya persaingan antar provider perusahaan telekomunikasi untuk bersaing mendapatkan pelanggan.

Untuk menentukan strategi bisnis kedepannya, StarTelco berharap mendapatkan insight dan prediksi dari team data science dan team marketing agar perusahaan dapat mempertahankan pelanggan dan menaikan keuntungan seperti sebelumnya.

Solution

Untuk menjawab permasalahan tersebut, team data science akan melakukan evaluasi dan mempelajari data perusahaan guna untuk memprediksi dan menentukan strategi bisnis berikutnya. Team data science akan menggunakan model XGBoosts, karena kecepatan, efisiensi, dan kemampuan menghasilkan prediksi yang akurasinya akurat.

BINAR

About data

Dataset ini berisi 4250 sampel. Setiap sampel berisi 19 fitur dan 1 variabel boolean "churn" yang menunjukkan kelas sampel. 19 fitur masukan dan 1 variabel target adalah:

- **"state"**, string. 2-letter code of the US state of customer residence
- **"account_length"**, numerical. Number of months the customer has been with the current telco provider
- **"area_code"**, string="area_code_AAA" where AAA = 3 digit area code.
- **"international_plan"**, (yes/no). The customer has international plan.
- **"voice_mail_plan"**, (yes/no). The customer has voice mail plan.
- **"number_vmail_messages"**, numerical. Number of voice-mail messages.
- **"total_day_minutes"**, numerical. Total minutes of day calls.
- **"total_day_calls"**, numerical. Total minutes of day calls.
- **"total_day_charge"**, numerical. Total charge of day calls.
- **-"total_eve_minutes"**-, numerical. Total minutes of evening calls.
- **-"total_eve_calls"**-, numerical. Total number of evening calls.
- **-"total_eve_charge"**-, numerical. Total charge of evening calls.
- **-"total_night_minutes"**-, numerical. Total minutes of night calls.
- **-"total_night_calls"**-, numerical. Total number of night calls.
- **-"total_night_charge"**-, numerical. Total charge of night calls.
- **-"total_intl_minutes"**-, numerical. Total minutes of international calls.
- **-"total_intl_calls"**- numerical. Total number of international calls.
- **-"total_intl_charge"**-, numerical. Total charge of international calls
- **-"number_customer_service_calls"**-, numerical. Number of calls to customer service
- **-"churn"**-, (yes/no). Customer churn - target variable.

BINAR

Explotartory Data Analysis

Pada EDA ini gambar di samping menunjukan permbersihan dan memperbaiki data guna untuk menunjang hasil terbaik saat training model.

```
#Delete area_code sentence from area_code column
train['area_code'] = train['area_code'].str.extract('(\d+)')

#Correct innappropriate data type from train dataset base on Attribute Information
train['international_plan'] = np.where(train['international_plan'] == 'no', 0, 1).astype('int64')
train['voice_mail_plan'] = np.where(train['voice_mail_plan'] == 'no', 0, 1).astype('int64')
train['churn'] = np.where(train['churn'] == 'no', 0, 1).astype('int64')

#Recheck The Data Summary
data_summary(train)
```

	Features	Data Types	Missing Values	Number of Unique Values	Unique Value
0	state	object	0	51	[OH, NJ, OK, MA, MO, LA, WV, IN, RI, IA, MT, N...
1	account_length	int64	0	215	No unique value
2	area_code	object	0	3	[415, 408, 510]
3	international_plan	int64	0	2	No unique value
4	voice_mail_plan	int64	0	2	No unique value
5	number_vmail_messages	int64	0	46	No unique value
6	total_day_minutes	float64	0	1843	No unique value
7	total_day_calls	int64	0	120	No unique value
8	total_day_charge	float64	0	1843	No unique value
9	total_eve_minutes	float64	0	1773	No unique value
10	total_eve_calls	int64	0	123	No unique value
11	total_eve_charge	float64	0	1572	No unique value
12	total_night_minutes	float64	0	1757	No unique value
13	total_night_calls	int64	0	128	No unique value
14	total_night_charge	float64	0	992	No unique value
15	total_intl_minutes	float64	0	168	No unique value
16	total_intl_calls	int64	0	21	No unique value
17	total_intl_charge	float64	0	168	No unique value
18	number_customer_service_calls	int64	0	10	No unique value
19	churn	int64	0	2	No unique value

BINAR

Kenapa sih???

Kenapa sih kita ambil model XGBoosts????

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
xgboost	Extreme Gradient Boosting	0.9570	0.9188	0.7422	0.9407	0.8280	0.8039	0.8123	0.1250
lightgbm	Light Gradient Boosting Machine	0.9546	0.9140	0.7232	0.9433	0.8156	0.7905	0.8013	0.2300
rf	Random Forest Classifier	0.9533	0.9197	0.7016	0.9540	0.8063	0.7806	0.7938	0.0800
gbc	Gradient Boosting Classifier	0.9516	0.9177	0.7231	0.9174	0.8068	0.7796	0.7880	0.1440
et	Extra Trees Classifier	0.9301	0.9142	0.5301	0.9517	0.6790	0.6436	0.6793	0.0600
dt	Decision Tree Classifier	0.9186	0.8318	0.7110	0.7145	0.7109	0.6637	0.6648	0.0180
knn	K Neighbors Classifier	0.8884	0.6866	0.3151	0.7487	0.4417	0.3912	0.4375	0.5690
ada	Ada Boost Classifier	0.8773	0.8548	0.3772	0.6128	0.4647	0.3998	0.4160	0.0490
nb	Naive Bayes	0.8719	0.8414	0.5512	0.5491	0.5483	0.4739	0.4750	0.0160
lr	Logistic Regression	0.8693	0.8302	0.2242	0.6039	0.3251	0.2691	0.3108	0.6600
lda	Linear Discriminant Analysis	0.8649	0.8256	0.2959	0.5417	0.3806	0.3122	0.3313	0.0160
ridge	Ridge Classifier	0.8645	0.0000	0.1073	0.6148	0.1813	0.1457	0.2144	0.0170
dummy	Dummy Classifier	0.8592	0.5000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0150
svm	SVM - Linear Kernel	0.7649	0.0000	0.2660	0.3129	0.1586	0.0966	0.1280	0.0180
qda	Quadratic Discriminant Analysis	0.5742	0.4841	0.4002	0.1942	0.1740	0.0057	0.0185	0.0170

Sub Topic

Pada gambar disamping menunjukan variabel X dan Y untuk kebutuhan training model

```
#Define X and Y
X = train.drop('churn', axis=1)
Y = train['churn']
```

```
outliers_check(X)
```

	Feature	Outliers (%)
0	account_length	0.47
1	international_plan	9.32
2	voice_mail_plan	0.00
3	number_vmail_messages	2.02
4	total_day_minutes	0.59
5	total_day_calls	0.66
6	total_day_charge	0.61
7	total_eve_minutes	0.80
8	total_eve_calls	0.56
9	total_eve_charge	0.80
10	total_night_minutes	0.87
11	total_night_calls	0.78
12	total_night_charge	0.87
13	total_intl_minutes	1.46
14	total_intl_calls	2.35
15	total_intl_charge	1.46
16	number_customer_service_calls	7.88

BINAR

Model development process

Dalam upaya kami memprediksi churn pelanggan bagi penyedia telekomunikasi, kami memerlukan cara untuk mengukur seberapa baik kinerja model kami.

Ada beberapa metrik yang tersedia untuk mengevaluasi model klasifikasi, masing-masing memiliki tujuan berbeda. Salah satu metrik yang umum adalah akurasi, yang mengukur proporsi instance yang diklasifikasikan dengan benar di semua instance. Namun, akurasi saja mungkin bukan pilihan terbaik untuk model prediksi churn kami.

BINAR

Model performance evaluation (confusion matrix)

Dalam eksplorasi model pengklasifikasi untuk memprediksi churn dalam layanan telekomunikasi, kami telah mengevaluasi berbagai opsi. Diantaranya, XGBoost menonjol sebagai pilihan optimal. XGBoost, kependekan dari Extreme Gradient Boosting, telah menunjukkan kinerja unggul dalam hal recall dan nilai F1 dibandingkan pengklasifikasi lain yang tersedia. Kekuatannya terletak pada kemampuannya menangani kumpulan data kompleks secara efektif dan mempelajari pola rumit, yang sangat penting untuk memprediksi churn pelanggan secara akurat.

```
Classification Report for Training Data
              precision    recall  f1-score   support

           0       0.97      0.98      0.97      1096
           1       0.84      0.82      0.83       179

    accuracy                           0.95      1275
   macro avg       0.91      0.90      0.90      1275
weighted avg       0.95      0.95      0.95      1275

Confusion Matrix for Training Data
[[1069   27]
 [  33  146]]
```

Kesimpulan

Dalam pemodelan ini XGBoosts menunjukan hasil dan performa yang sangat bagus diantara model yang lain. Selain itu, interpretasi XGBoost adalah aset berharga dalam konteks prediksi churn.

Kemampuannya untuk memberikan wawasan tentang fitur mana yang paling berpengaruh dalam menentukan churn memungkinkan penyedia telekomunikasi mendapatkan pemahaman yang lebih mendalam tentang perilaku pelanggan dan menyesuaikan strategi retensi.

Secara keseluruhan, XGBoost muncul sebagai model ideal untuk prediksi churn, menawarkan kombinasi kuat antara kinerja tinggi, keserbagunaan, dan kemampuan interpretasi untuk secara efektif mengatasi tantangan retensi pelanggan di industri telekomunikasi.

Report Pembagian Pengerjaan Tugas

Report Pembagian Tugas

Nama	Tasklist/Deliverable
Muhamad Shidqi	Paling banyak dalam pembuatan query dan program selama pelatihan ini dan juga terlibat dalam pembuatan visualisasi.
Mohammad Rifqi Nur Faroza	Paling banyak dalam pembuatan visualisasi data dan juga turut andil dalam pembuatan program code.

BINAR

Thank You